软件工程学士论文答辩

基于多社交媒体的个体信息融合

关键技术研究

学生姓名:詹辉

指导老师: 崔晓晖 教授

内容提要

- 一、论文背景:
- 1. 社交媒体的使用现状;
- 2. 本阶段的社交媒体选择。
- 二、系统需求与设计:
 - 1. 本系统的需求分析;
 - 2. 本系统的模块设计。
- 三、系统实现:

介绍本系统关键部分的实现:

1. 数据采集; 2. 实体相关词抽取; 3. 信息融合。

四、处理结果:

显示本系统的处理结果。


一、论文背景

1. 融合的信息是什么?

(P9. 1.1.1选题的背景)

2. 为什么选择 <u>脸谱网</u> 与 <u>推特</u> 作 为现阶段的目标社交媒体?

(P16. 2.3数据来源)



二、系统需求与设计

1. 总体需求

获取一个个体在多个社交媒体中补 全后的较为完整的信息。

2. 功能需求

- 1)数据采集;
- 2) 文本预处理;
- 3) 文本实体抽取;
- 4) 实体相关词抽取:
- 5) 信息融合;
- 6) 处理结果读取;
- 7) 处理结果显示。

(P18. 3.1系统总体功能需求)

3. 模块设计



(P23. 4.1.2系统模块设计)

数据采集

1. 推特数据采集

采集地址: mobile.twitter.com

使用工具: requests

2. 脸谱网数据采集

采集地址: m. facebook. com

使用工具: selenium

(P35. 5.2数据采集模块)

文本预处理

文本实体识别

实体相关词抽取

信息融合

处理结果读取

处理结果显示



文本预处理

1. 文本切词

使用工具: Noah's ARK 切词工具



2. 单词标准化

使用工具: NLTK 词形还原工具(Lemmatization)

3. 词性标注

使用工具: NLTK 词性标注工具

PR VB RB NN JJ NN

文本实体 识别

实体相关词抽取

信息融合

处理结果读取

处理结果显示

文本实体识别

使用工具: MITIE 命名实体识别工具、NLTK 实体识别工具

PR VB RB NN JJ NN

(P39. 5.3.2.1文本实体识别)

(P38. 5.3.1预处理文本)

实体相关词 抽取

1. 基于文本词性句型的相关词抽取方法

举例说明:以(句型)NN NN VB JJ NN NN NN NN NN 为例 NN NN NN NN My daughter @lucy1995 won the special prize of this year's 已训练 NN NN annual painting competition. NN NN 待抽取 Jonathon Fury sent me a cute ted from Las Vegas NN NN Roling-Madam souvenir shop! Fury 相关词: sent, cute, ted, souvenir, shop.

信息融合

处理结果读取

处理结果显示

(P39. 5.3.2.2实体相关词抽取(1)句型方法)

实体相关词 抽取



对500个常见的词形句型进行手动标记,得到每一种句型对应的实体词抽取办法。(使用这500个常见句型的句子占整个语料库的10%)

人工标记:

```
STAT: Start marking 23 pattern.
STAT: Pattern: NN NN NN VB NN NN NN NN JJ.
STAT: Mark 7 text of the pattern.
                                        3
                                        VB
        NN
                        NN
                                NN
                                                NN
        Glenview
                                         found
                                                shot
                        man
                                wa
                                                         to
                                                         8
                6
                                        NN
                                                         JJ
                Chicago over
                                        weekend:
                                                         trib.in/1GZv0rW
                                the
        in
The indice of relevance: 1 3 5 7
```

信息融合 🛉

处理结果读取

处理结果显示

(P39. 5.3.2.2实体相关词抽取(1)句型方法)

实体相关词 抽取



卡方统计量常运用在检验两个事件的相互独立性。利用卡方统计量 计算实体词与实体词所在文本中的每一个词的相互独立性,得到的结 果中与实体词不相互独立的词,即为该实体的相关词。

举例说明:



在整个语料库中统计"实体词"与"词A"一起出现、一起不出现的频率,如果"词A"在语料库中明显呈现出与"实体词"同时出现以及同时不出现,则可断定"词A"与"实体词"不是相互独立的。

实体词与词A同时出现	56	实体词出现、词A不出现	7
实体词不出现、词A出现	21	实体词与词A同时不出现	19450

实体词与词B同时出现	1	实体词出现、词B不出现	58
实体词不出现、词B出现	41	实体词与词B同时不出现	19436

(P41. 5.3.2.2实体相关词抽取(2)卡方方法)

信息融合

处理结果读取

处理结果显示

实体相关词 抽取



卡方统计量则是计算两个词之间是否相互独立的量化数值,若卡方统计量超过10.83,则该二词相互独立的概率将低于0.001,近似与小概率事件。公式如下:

 e_{11} 计算公式 $(e_{10}, e_{01}, e_{00}$ 计算公式以此类推)

$$e_{11} = n * rac{n_{11} + n_{10}}{n} * rac{n_{11} + n_{01}}{n}$$
 , $n = n_{11} + n_{10} + n_{01} + n_{00}$

X2计算公式

$$\chi^2 = \sum_{e_t \in \{0,1\}} \sum_{e_c \in \{0,1\}} \frac{(n_{e_t e_c} - e_{e_t e_c})^2}{e_{e_t e_c}}$$

在上例中,通过计算可得:

词A与实体词的卡方统计量为: 12606.48


词B与实体词的卡方统计量为: 6.04

(P41. 5.3.2.2实体相关词抽取(2)卡方方法)


信息融合

处理结果读取

处理结果显示




1. 原始文本




(P44. 5.4.4.1原始社交文本)

2. 中间结果: 文本切词与单词标准化




(P45. 5.4.4.2文本切词与单词标准化)

2. 中间结果: 文本词性标注



(P45. 5.4.4.3文本词性标注)

2. 中间结果: 文本实体识别与实体相关词抽取



(P46. 5.4.4.4信息抽取)


Wuhan University ISS. Big Data & Cloud Computing Lab.

四、处理结果


- 3. 最终结果: 信息融合
 - 1) 是否能够表现融合的两个账户属于统一个个体;
 - 2) 是否能够补全一个个体在两个社交媒体中的不同信息。

(P20. 3.6信息融合功能)


3. 最终结果: 信息融合 User1(不同个体的账号)




3. 最终结果: 信息融合 User1(不同个体的账号)




3. 最终结果: 信息融合 User1(不同个体的账号)




3. 最终结果: 信息融合 User2 (同一个个体的账号)



3. 最终结果: 信息融合 User2 (同一个个体的账号)



3. 最终结果: 信息融合 User2 (同一个个体的账号)



结束

致 谢 THE END